

RAG

RAG PDF € • , f
Cache „ RISC-V „ ... † € ‡ „ ^ % Š < Œ • Ž • • ‘ ’
PDF “ ” • — ~ ™ Š > œ pypdf • Python • Ž Ÿ i Š > ¢ £ PDF
¤ „ ¥ | § Chunk „ Embedding „ Top-K > “ • © ª
« ¬ - ’ ® ¯ ° Cache ± ² ³ ´ μ ¶ · TLB
, ³ ´ • ^ % Š Ÿ ¹ º » ¼ ½ ¾ ¿ · RISC-V
À ³ ´ Á Â Ã · < Œ • Ž • À ³ ´ Ä Å Æ Ç È É • •

1. Cache Ê Ë Ì Í Î Ï

Cache Î CPU ' ÷ Î Ð Ñ ÷ Ò Ó CPU Ô Õ Ñ Ö × Ø Ù ' ÷ Ú - Ñ Ò Ù Ù Ý —
 Þ ß à ¶ á â ã • ä ' ÷ å æ ç è — é ê ë ì í î ï Ä Cache • ï ð ñ ò Ñ Ò ó Ù ÷
 Ò á ô ÷ õ ö š Ä æ ÷ ø Ú - ç è ù ú — û ü ý þ • ž Ú - ' ÷ ø ç

Cache Ä Å ÿ , è Ú - Ë Ì Í Î Ï Ð Ë Ì Í ç è ù ú
 æ Ú - — ð Ð € ÷ ø æ Ú - ç ð Ñ Ð Ë Ì Í Ú - — ð
 æ Ú - ç ð Ñ

Cache — à ¶ á š › • ž û Cache Ü ç è Cache
 — û ó ì Ó ø ÷ Ò á æ ç è — ê ! " miss
 penalty ç „ Ú - ° » # \$ ê % & ' (÷ Ò) * + , Ú - Ð

2. RISC-V ù ú - . /

RISC-V 0 1 2 3 4 ù ú - . / ¢ 5 6 § 7 8 9 — : ; í ç ù ú - š > < Â = > ?
„ @ A „ µ B C , „ D ĭ • E F 1 G H š > I è à ¶ á J K L E F

RISC-V 1 2 M N O ã „ P Q à ¶ á µ R 8 9 š > û ð ñ : ; ù ú - S T —
U V ¶ É ù ú Ž • „ ç è × W „ X Y Z [„ ^ % Š \ Ø à ¶ • î)] / ^

3 4 ù ú - _ “ ` a b à ¶ á c Ä Ö Œ 4 d e f — ü g M h ù ú Ž • „ ð þ i j k
l m > “ Á Â ^ % Š n o 8 9 µ h

3. ... † € ‡ Ê TLB

... † € ‡ 0 € ‡ p ¶ q Y r ... † —ü C ,) * s — t u v ... † w x
y z ¶ × { ... † Ð — “ & | š > } ~ • € • , N f — û ü Ÿ ¹ „ ... Í
p ¶ † ‡ Í

ô ‡ ... † y z ¶ ^ Ĩ Ð w x %) • ž Ů - Ý Š š Ä Ý ø € ‡ Ů - —
à ¶ á × Ø r TLB Translation Lookaside
Buffer—Ů < ‡ Æ õ r { • Ž] ß

TLB — • Ž š > • Ů • TLB — ‘ ’ _ v “ w x ” S
TLB TLB š > ý þ • Ž { ! " 1 •

4. ù ú ^ % Š

^ % Š v – ù ú Ô Õ { — Ý ~™ — _ š Ý – ù ú “ & ~™ & | Õ > æ • Š
^ % Š × Ø ® ¯ ù „ ž • „ Ô Õ „ Ú ‡ ” æ

^ % Š ‘ , Ÿ ¹ ù ú ½ ¾ Ć — Ÿ é d î Đ € • ó Ý ù ú ¢ × Ø “ ê • ž
d – ù ú û 1 i y j ¢ £ ° » ¶ ¢ ¥ | § — “ Š ^ % Š š > © ª « ö ¬ | –
“ ù ú

- n à ¶ á ê ® y j / ¯ ° „ ç è ¯ ° X Y ¯ ° Ø ± É ² | ? ® ¯ • G „ ³ ´ > “ μ ¶
· ^ % Š í Ä , y Š ç „ ª « ö ¯ ° à ¶ ¹ ° % & ' (

5. <Œ•Ž•

<Œ•Ž• 0Æ»¼½Ž•|? ¢|è¾¿Àoâ¿/ÁÂÃÄ—š¹â¾¿Üð
Ž•—šìâ¾¿Üð½Ž•—ûüëì+, Ž•½Ö

<Œ•Ž•Å~ÆÇ•ÍÈ°eÉ¾¿Ž•Ê“Ë¾¿Ž•ÆÇûÙ
ì^1¡—š>Í<Œ•ÄUVÎ<_İĐÑ©¾¿—“!“μ•¾

<Œ•Ž•çèÒÓÔŽ•ÕØ>œ¢ÁÂÖ¶É×Ø?„Ä]/„Ž•½
ÖÊ¾¿¿İĐ‰)